# High Performance Computing und Paralleles Rechnen

Dr. Momin Ahmad, Marcel Weichel

**HS Karlsruhe** 

27-11-2023

# Teil I

# **Advanced MPI**

#### Inhaltsverzeichnis I

1 Motivation

- 2 Communicator/Groups
  - Groups
  - Communicators

- 3 Virtuelle Topologien
  - Aufgabe von Topologien
  - Kartesische Topologie
  - MPI Funktionen für Topologie

#### Inhaltsverzeichnis II

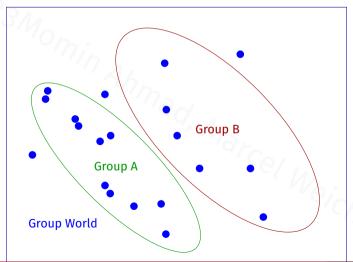
- 4 MPI-IO
  - Standard IO
  - Lesen und Schreiben mit MPI-IO
  - Views in MPI-IO
  - Kleiner Exkurs: selbstdefinierte MPI-Typen
  - Kollektives MPI-IO
  - Kleiner Exkurs: Aufbau parallele Dateisystem
  - Hints for faster IO
- 5 Grenzen von MPI
- 6 Abschluss

#### Motivation

- Verwalten von Prozessen anhand von Topologien
- Paralleles Speichern/Lesen von Daten



#### **Groups and Communicators**





#### **Groups, Context, Communicators**

Group Gruppe von Prozessen

Context Kommunikationskontext (Eigenschaft eines Communicators)

Communicator Führt eine Gruppe und einen Context zusammen

#### Group

#### MPI Group

"A **group** is an ordered set of process identifiers (henceforth processes); processes are implementation-dependent objects. Each process in a group is associated with an integer rank. Ranks are contiguous and start from zero. Groups are represented by opaque group objects, and hence cannot be directly transferred from one process to another. A group is used within a communicator to describe the participants in a communication universe and to rank such participants." [For12, S. 226]

#### Context

#### **MPI Context**

"A **context** is a property of communicators that allows partitioning of the communication space. A message sent in one context cannot be received in another context. Furthermore, where permitted, collective operations are independent of pending point-to-point operations. Contexts are not explicit MPI objects; they appear only as part of the realization of communicators." [For12. S. 226]

#### Communicator

#### **MPI Intra-Communicator**

"Intra-communicators bring together the concepts of group and context. To support implementation-specifc optimizations, and application topologies, communicators may also cache additional information. MPI communication operations reference communicators to determine the scope and the communication universe in which a point-to-point or collective operation is to operate. Each communicator contains a group of valid participants; this group always includes the local process. The source and destination of a message is identified by process rank within that group. For collective communication, the intra-communicator specifies the set of processes that participate in the collective operation (and their order, when significant). Thus, the communicator restricts the spatial scope of communication, and provides machine-independent process addressing through ranks. Intra-communicators are represented by opaque intra-communicator objects, and hence cannot be directly transferred from one process to another" [For12, S. 227]

Anmerkung: Inter-Kommunikatoren (für Kommunikation zwischen Gruppen) hier nicht behandelt.

Groups





#### MPI\_Group\_size

# Aufgabe

Gibt die Anzahl an Prozessen in der Gruppe zurück

```
int MPI_Group_size(
MPI_Group group, //[in] group
int *size //[out] number of processes in the group
);
```





#### MPI\_Group\_rank

## Aufgabe

Gibt die rank ID des Prozesses in der Gruppe zurück

```
int MPI_Group_rank(
MPI_Group group, //[in] group
int *rank //[out] rank of the calling process in group, or MPI_UNDEFINED if the process is
not a member

);
```





#### MPI\_Group\_incl

## Aufgabe

Erzeugt eine neue Gruppe basierend auf der bestehenden Gruppe mit den rank IDs aus der übergebenen Liste

```
int MPI_Group_incl(
MPI_Group group, //[in] group
int n, //[in] number of elements in array ranks
int *ranks, //[in] ranks of processes in group to appear in newgroup
MPI_Group *newgroup //[out] new group derived from above, in the order defined by ranks
);
```





#### MPI\_Group\_excl

## Aufgabe

Erzeugt eine neue Gruppe basierend auf der bestehenden Gruppe ohne die rank IDs aus der übergebenen Liste

```
int MPI_Group_excl(
MPI_Group group, //[in] group
int n, //[in] number of elements in array ranks
int *ranks, //[in] array of integer ranks in group not to appear in newgroup
MPI_Group *newgroup //[out] new group derived from above, preserving the order defined by group
);
```





#### MPI\_Group\_range\_incl

## Aufgabe

Erzeugt eine neue Gruppe basierend auf der bestehenden Gruppe mit den Bereichen von rank IDs aus der Liste

```
int MPI_Group_range_incl(

MPI_Group group, //[in] group

int n, //[in] number of triplets in array ranges

int ranges[][3], //[in] a one - dimensional array of integer triplets, of the form (first rank, last rank, stride) indicating ranks in group or processes to be included in newgroup.

MPI_Group *newgroup //[out] new group derived from above, in the order defined by ranges

MPI_Group *newgroup //[out] new group derived from above, in the order defined by ranges

| The processes of the included in newgroup in the order defined by ranges | The processes | The proces
```





#### MPI\_Group\_range\_excl

## Aufgabe

Erzeugt eine neue Gruppe basierend auf der bestehenden Gruppe ohne die Bereiche von rank IDs aus der Liste

```
int MPI_Group_range_excl(
MPI_Group group, //[in] group
int n, //[in] number of triplets in array ranges
int ranges[][3], //[in] a one - dimensional array of integer triplets of the form (first rank,
last rank, stride), indicating the ranks in group of processes to be excluded from the output group
newgroup.

MPI_Group *newgroup //[out] new group derived from above, preserving the order in group
);
```





#### MPI\_Group\_intersection

## Aufgabe

Erzeugt eine neue Gruppe durch Schnitt der beiden Gruppen

```
int MPI_Group_intersection(
MPI_Group group1, //[in] first group
MPI_Group group2, //[in] second group
MPI_Group *newgroup //[out] intersection group

);
```





#### MPI\_Group\_difference

## Aufgabe

Erzeugt eine neue Gruppe durch Differenz der beiden Gruppen

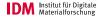
```
int MPI_Group_difference(
    MPI_Group group1, //[in] first group

MPI_Group group2, //[in] second group

MPI_Group *newgroup //[out] difference group

);
```





#### MPI\_Group\_union

## Aufgabe

Erzeugt eine neue Gruppe durch Vereinigung der beiden Gruppen

```
int MPI_Group_union(
MPI_Group group1, //[in] first group
MPI_Group group2, //[in] second group
MPI_Group *newgroup //[out] union group
);
```





#### MPI\_Group\_compare

# Aufgabe

Vergleich von zwei Gruppen auf Gleichheit

```
int MPI_Group_compare(

MPI_Group group1, //[in] group1

MPI_Group group2, //[in] group2

int *result //[out] integer which is MPI_IDENT if the order and members of the two groups are the same, MPI_SIMILAR if only the members are the same, and MPI_UNEQUAL otherwise

5 );
```





#### MPI\_Group\_free

# Aufgabe

Löschen einer Gruppe

```
int MPI_Group_free(
    MPI_Group *group //[in] group to free
);
```





#### MPI\_Group\_translate\_ranks

## Aufgabe

Übersetzt die rank IDs von einer Gruppe in die rank IDs der anderen Gruppe

```
int MPI_Group_translate_ranks(
  MPI_Group group1, //[in] group1
  int n,
                                                 ranks1 and ranks2
  int *ranks1. //[in] array
  MPI_Group group2, //[in] group2
  int *ranks2
                        //[out] array
                                          corresponding
                                                                          MPI UNDEFINED
                                     of
                                                       ranks in
                                                                 aroun2 .
                                                                                        when no
  correspondence
             exists .
```





#### MPI\_Comm\_rank

## Aufgabe

Gibt die rank ID des Prozesses im Communicator zurück

```
int MPI_Comm_rank(
  MPI_Comm comm,
                     //[in]
                             communicator
  int *rank
                     //[out] rank of the
                                          calling
```





#### MPI\_Comm\_size

## Aufgabe

Gibt die Anzahl an Prozessen im Communicator zurück

```
int MPI_Comm_size(
MPI_Comm comm, //[in] communicator
int *size //[out] number of processes in the group of comm
);
```





#### MPI\_Comm\_create

## Aufgabe

Erzeugt einen neuen Communicator

```
int MPI_Comm_create(
MPI_Comm comm, //[in] communicator
MPI_Group group, //[in] group, which is a subset of the group of comm
MPI_Comm *newcomm //[out] new communicator
);
```





#### MPI\_Comm\_dup

## Aufgabe

**Dupliziert einen Communicator** 

```
int MPI_Comm_dup(
    MPI_Comm comm, //[in] Communicator to be duplicated
    MPI_Comm *newComm //[out] A new communicator over the same group as comm but with a new context .
);
```





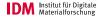
#### MPI\_Comm\_group

# Aufgabe

Gibt die Gruppe auf dem der Communicator basiert zurück

```
int MPI_Comm_group(
    MPI_Comm comm, //[in] Communicator
    MPI_Group *group //[out] Group in communicator
);
```





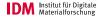
#### MPI\_Comm\_set\_name

## Aufgabe

Setzt den Namen für einen Communicator

```
int MPI_Comm_set_name(
MPI_Comm comm, //[in] communicator to name
char *comm_name //[in] Name for communicator
);
```





#### MPI\_Comm\_get\_name

# Aufgabe

Gibt den Namen des Communicators zurück

```
int MPI_Comm_get_name(

MPI_Comm comm, //[in] Communicator to get name of (handle)

char *comm_name, //[out] On output, contains the name of the communicator. It must be an array of size at least MPI_MAX_OBJECT_NAME.

int *resultlen //[out] Number of characters in name

);
```





#### MPI\_Comm\_free

# Aufgabe

Löscht den Communicator

```
int MPI_Comm_free(
MPI_Comm *comm //[in] Communicator to be destroyed
);
```



#### **Vordefinierte Gruppen und Communicatoren**

MPI\_GROUP\_EMPTY Gruppe ohne Prozesse

MPI\_COMM\_WORLD Communicator mit allen Prozessen

MPI\_COMM\_SELF Communicator mit nur dem eigenen Prozess

MPI\_GROUP\_NULL Wert für ungültige Gruppe

MPI\_COMM\_NULL Wert für ungültigen Communicator



#### **MPI Communicator Example**

```
<MPT Rasis..init ?? >
   int me, count, count2;
   void *send_buf, *recv_buf, *send_buf2, *recv_buf2;
  MPI_Group mpi_group_world, grprem;
  MPI Comm commrem:
   static int ranks[] = {0}:
  MPI_Comm_group(MPI_COMM_WORLD, &mpi_group_world);
  MPI_Comm_rank(MPI_COMM_WORLD, &me); /* local */
  MPI_Group_excl(mpi_group_world, 1, ranks, &grprem); /* local */
  MPI_Comm_create(MPI_COMM_WORLD, grprem, &commrem);
   if (me != 0) {
12
     /* compute on worker */
13
14
     MPI_Reduce(send_buf, recv_buf, count, MPI_INT, MPI_SUM, 1, commrem);
16
     MPI_Comm_free(&commrem);
17
18
   /* zero falls through
                       immediately to this reduce others do later ... */
19
  MPI_Reduce(send_buf2, recv_buf2, count2,
MPI INT, MPI SUM, O, MPI COMM WORLD):
MPI_Group_free(&mpi_group_world);
  MPI Group free(&grprem):
                                                                                             Ouelle: [For12, S, 251f,]
```

391 / 653





#### **MPI Communicator Example I**

```
<MPT Basis::init ?? >
   int ma. mb:
  MPI_Group mpi_group_world, group_a, group_b;
  MPI_Comm comm_a, comm_b;
   static int list_a[] = {0, 1};
   #if defined(EXAMPLE_2B) || defined(EXAMPLE_2C)
   static int list_b[] = \{0, 2, 3\};
8 #else/* EXAMPLE 2A */
   static int list_b[] = {0, 2};
  #endif
10
   int size list a = sizeof(list a)/sizeof(int);
   int size_list_b = sizeof(list_b)/sizeof(int);
13
  MPI Comm group (MPI COMM WORLD, &mpi group world);
  MPI Group incl(mpi group world, size list a, list a, &group a):
  MPI_Group_incl(mpi_group_world, size_list_b, list_b, &group_b);
  MPI_Comm_create(MPI_COMM_WORLD, group_a, &comm_a);
MPI_Comm_create(MPI_COMM_WORLD, group_b, &comm_b);
if(comm a != MPI COMM NULL)
     MPI Comm rank(comm a, &ma);
20
   if(comm b != MPI COMM NULL)
```



### **MPI Communicator Example II**

```
MPI_Comm_rank(comm_b, &mb);
22
   if(comm a != MPI COMM NULL)
   lib_call(comm_a);
   if(comm_b != MPI_COMM_NULL) {
25
     lib_call(comm_b);
26
     lib_call(comm_b);
27
28
   if(comm_a != MPI_COMM_NULL)
     MPI_Comm_free(&comm_a);
30
   if(comm b != MPI_COMM_NULL)
     MPI Comm free(&comm b):
   MPI_Group_free(&group_a);
   MPI_Group_free(&group_b);
  MPI_Group_free(&mpi_group_world);
   <MPI Basis::deinit ?? >
```

### **Virtual Topologies**

- Prozesse werden auf eine Topologie/Struktur abgebildet
  - Gitter/Kartesische Topologie
  - Ring
  - Graph
- Prozesse könnten entsprechend dem Problem angeordnet werden
- müssen nicht/können aber mit der Topologie der Hardware/Netzwerk übereinstimmen
- Erzeugen von Unter-Topologien
- Bestimmen von Nachbarn
- Virtuelle Topologien sind Attribute des Communicators



## **Kartesische Topologie**

<b>10</b> (0,2)	<b>11</b> (1,2)	<b>12</b> (2,2)	<b>13</b> (3,2)	<b>14</b> (4,2)
<b>5</b> (0,1)	<b>6</b> (1,1)	<b>7</b> (2,1)	<b>8</b> (3,1)	<b>9</b> (4,1)
<b>o</b> (0,0)	<b>1</b> (1,0)	<b>2</b> (2,0)	<b>3</b> (3,0)	<b>4</b> (4,0)





### MPI\_Cart\_create

## Aufgabe

Erzeugt einen neuen Communicator basierend auf der übergebenen kartesischen Topologie

## Signatur

```
int MPI_Cart_create(
  MPI_Comm comm_old.
                          //[in] input
  int ndims.
                          //[inl number
  int *dims.
                          //[in] integer
                                                                specifying
                                         array of size ndims
                                                                           the number of
                                                                                            processes
 dimension
  int *periods.
                          //[in] logical
                                                                specifying
                                                  size ndims
true ) or not (false ) in each
  int reorder.
                          //[in] ranking
                                                  reordered
  MPI Comm *comm cart //[out] communicator
                                                           cartesian
```

Anmerkung: Siehe auch 2D Gebietszerlegung





### MPI\_Cart\_rank

## Aufgabe

Gibt die rank ID für die übergebenen Koordinaten in der kartesischen Topologie zurück

## Signatur

```
int MPI_Cart_rank(
  MPI_Comm comm, //[in]
  int *coords.
                      //[in]
                             integer
                                      array (of
                                                                                                      Cartesian
 topology
            associated
                        with
                                      specifying
                                                       cartesian
                                                                   coordinates
  int *rank
                     //[out]
                                       specified
                                                   process
```

Anmerkung: Bei nicht periodischen Rändern muss "coords" im Gitter liegen

.....հ....հումիավայիավարիավայիավարիան





### MPI\_Cart\_coords

## Aufgabe

Gibt die Koordinaten für eine rank ID in der kartesischen Topologie zurück

```
int MPI_Cart_coords(
  MPI_Comm comm, //[in]
  int rank.
                      //[in]
                                         process
                                                  within
  int maxdims,
                      //[in]
                                         vector
                                                                  calling
  int *coords
                      //[out]
                              integer
                                                         ndims )
                                                                  containing
                                                                                                coordinates
 specified
            process
```





### MPI\_Cart\_get

# Aufgabe

Gibt die kartesischen Topologie-Informationen zurück

```
int MPI_Cart_get(
  MPI_Comm comm, //[in]
  int maxdims.
                      //[in]
                                                                          coords in
                                                                                                    program
  int *dims,
                      //[out]
                               number of
                                                                  cartesian
  int *periods,
                      //[out]
                               periodicity
                                            ( true / false )
                                                           for
                                                                                    dimension
                                                                 each
  int *coords
                      //[out]
                               coordinates
                                                 calling
                                                          process
                                                                        cartesian
                                                                                    structure
```





### MPI\_Cart\_shift

## Aufgabe

Gibt die rank ID des benachbarten Prozess in der kartesischen Topologie zurück

## Signatur

```
int MPI_Cart_shift(
  MPI_Comm comm, //[in]
                                                         structure
  int direction, //[in] coordinate
                                       dimension
                                                of shift
  int displ,
               //[in]
                           displacement
                                               upwards
                                                     shift . < 0: downwards
                                                                               shift )
  int *source, //[out]
  int *dest
              //[out]
                           rank of
                                     destination
                                                 process
```

Anmerkung: Source ist der Rank in positive und Destination der in negative Shift-Richtung.





### MPI\_Cart\_sub

## Aufgabe

Erzeugt einen neuen Communicator in dem die kartesischen Topologie um eine oder mehrere Dimensionen reduziert wird

```
int MPI_Cart_sub(
  MPI_Comm comm,
                         //[in]
                                 communicator
                                                      cartesian
                                                                  structure
  int *remain_dims, //[in] the ith entry of
                                                     remain dims
                                                                  specifies
                                                                                                 dimension
in the subgrid (true) or is dropped
  MPI_Comm *newcomm //[out]
                                  communicator
                                                 containing
                                                                  subarid
                                                                                 includes
                                                                                                calling
                                                                                                          process
```

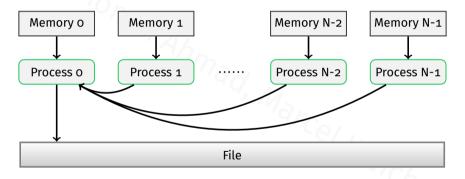


### Kartesische Untertopologien

<b>10</b> (0,2)	<b>11</b> (1,2)	<b>12</b> (2,2)	<b>13</b> (3,2)	<b>14</b> (4,2)
<b>5</b> (0,1)	<b>6</b> (1,1)	<b>7</b> (2,1)	<b>8</b> (3,1)	<b>9</b> (4,1)
<b>o</b> (o,o)	<b>1</b> (1,0)	<b>2</b> (2,0)	<b>3</b> (3,0)	<b>4</b> (4,0)



### Datei für alle Prozesse





### I/O über Master-Prozess

```
example of
                  sequential
                             Unix
                                 write into a common
                                                     file */
   <MPI Basis::init ?? >
       #define BUFSIZE 100
3
       int i. buf[BUFSIZE]:
       MPI_Status status;
       FILE *myfile;
       for (i=0: i<BUFSIZE: i++)</pre>
          buf[i] = myrank * BUFSIZE + i;
       if (myrank != 0)
10
          MPI_Send(buf, BUFSIZE, MPI_INT, 0, 99, MPI_COMM_WORLD);
11
        else {
12
          mvfile = fopen("testfile", "w");
13
          fwrite(buf, sizeof(int), BUFSIZE, myfile);
14
          for (i=1; i<numprocs; i++) {</pre>
15
             MPI Recv(buf, BUFSIZE, MPI INT, i, 99, MPI COMM WORLD, &status);
16
             fwrite(buf, sizeof(int), BUFSIZE, myfile);
17
18
          fclose(myfile);
19
20
   <MPI Basis::deinit ?? >
```

Quelle: [GLT99], http://www.mcs.anl.gov/research/projects/mpi/usingmpi2/examples/starting/main.htm, 01.12.2013

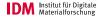
### Datei für alle Prozesse

### Vorteile

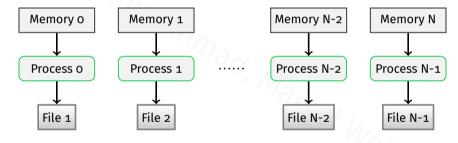
- Benutzung von Standard I/O Libarys
- Arbeiten mit nur einer Datei
- Schreiben/Lesen von großen chunks

### **Nachteile**

- Skaliert nicht für viele Prozesse/große Datenmengen
- Nutzt parallele Dateisysteme nicht aus
- Setzen der Daten an entsprechende Stelle in der Datei kann aufwendig und teuer (seeks) sein



### **Eine Datei pro Prozess**



### **Eine Datei pro Prozess**

```
into
                                          separate
                                                  files */
   <MPI Basis::init ?? >
   #define BUFSIZE 100
       int buf[BUFSIZE];
       char filename[128];
       FILE *myfile;
       for (i=0; i<BUFSIZE; i++)</pre>
         buf[i] = myrank * BUFSIZE + i;
        sprintf(filename, "testfile.%d", myrank);
       myfile = fopen(filename, "w");
       fwrite(buf, sizeof(int), BUFSIZE, myfile);
12
       fclose(myfile);
13
   <MPI Basis::deinit ?? >
```

Quelle: [GLT99], http://www.mcs.anl.gov/research/projects/mpi/usingmpi2/examples/starting/main.htm, 01.12.2013

## **Eine Datei pro Prozess**

### Vorteile

- Benutzung von Standard I/O Libarys
- Sehr einfach zu implementieren

### **Nachteile**

- Viele kleine Dateien
- Müssen möglicherweise nachträglich zusammengesetzt werden
- Dateisystem bekommt bei vielen Prozessen und kleinen chunks Probleme
- Zur weiteren parallelen Verarbeitung müssen gleich viele Prozesse verwendet werden oder zusätzlicher Implementierungsaufwand nötig

### MPI-IO

### Vorteile

- Erweiterung zum parallelen Lesen und Schreiben von Daten
- Hilfsfunktionen zum Lesen/Schreiben von kleinen, verteilten Chunks
- Kollektive Lese-/Schreib-Funktionen für schnelles I/O

### Nachteile

- Benötig ein paralleles Dateisystem für leistungszuwachs
- Nicht mehr volle Kontrolle über Daten und Lese-/Schreib-Prozesse





### MPI\_File\_open

## Aufgabe

Öffnen einer Datei mit MPI-IO

```
int MPI_File_open(
MPI_Comm comm, //[in] communicator
char *filename, //[in] name of file to open
int amode, //[in] file access mode
MPI_Info info, //[in] info object
MPI_File *mpi_fh //[out] file handle
);
```



#### Institut für Digitale Materialforschung

### MPI\_File\_open

Options werden mit Oder "|" verknüpft übergeben

MPI\_MODE\_RDONLY Nur lesen

MPI\_MODE\_WRONLY Nur schreiben

MPI\_MODE\_RDWR Lesen und schreiben

MPI\_MODE\_CREATE Erzeugen wenn noch nicht vorhanden

MPI\_MODE\_EXCL Fehler wennn schon vorhanden

MPI\_MODE\_DELETE\_ON\_CLOSE Löschen wenn Datei geschlossen wird

MPI\_MODE\_UNIQUE\_OPEN Datei wird nur von diesem Prozess geöfnet

MPI\_MODE\_SEQUENTIAL Datei wird nur sequentiell geöffnet

MPI\_MODE\_APPEND Alle Datei-Pointer an das Ende der Datei setzen





### MPI\_File\_close

## Aufgabe

Schließen einer Datei mit MPI-IO

```
int MPI_File_close(
MPI_File *mpi_fh //[in] file handle

b);
```





### MPI\_File\_delete

## Aufgabe

Löschen einer Datei mit MPI-IO

```
int MPI_File_delete(
char *filename, //[in] name of file to delete

MPI_Info info //[in] info object

);
```





### MPI\_File\_get\_size

## Aufgabe

Bestimmen der Größe einer Datei mit MPI-IO

```
int MPI_File_get_size(
MPI_File mpi_fh, //[in] file handle
MPI_Offset *size //[out] size of the file in bytes

(A);
```





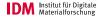
### MPI\_File\_read

## Aufgabe

Lesen einer Datei mit MPI-IO

```
int MPI_File_read(
MPI_File mpi_fh, //[in] file handle
void *buf, //[out] initial address of buffer
int count, //[in] number of elements in buffer
MPI_Datatype datatype, //[in] datatype of each buffer element
MPI_Status *status //[out] status object
);
```





### MPI\_File\_write

# Aufgabe

Schreiben in eine Datei mit MPI-IO





### MPI\_File\_sync

## Aufgabe

Flush aller Daten mit MPI-IO

```
int MPI_File_sync(
MPI_File mpi_fh //[in] file handle

);
```





### MPI\_File\_seek

## Aufgabe

Springen an eine Position innerhalb einer Datei mit MPI-IO

## MPI\_File\_seek

MPI\_SEEK\_SET pointer wird an Offset gesetzt

MPI\_SEEK\_CUR pointer wird um den übergeben Offset verschoben

MPI\_SEEK\_END pointer wird ans Ende plus den Offset verschoben

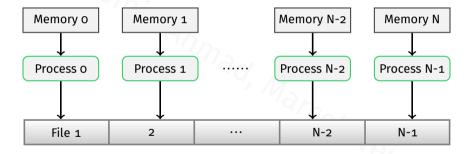
### **MPI-IO: eine Datei pro Prozess**

```
of parallel MPI
                             urite
                                   into
                                         separate
                                                files */
   <MPI Basis::init ?? >
   #define BUFSIZE 100
       int i, buf[BUFSIZE];
       char filename[128]:
       MPI_File mvfile:
       for (i=0; i<BUFSIZE; i++)</pre>
            buf[i] = mvrank * BUFSIZE + i;
       sprintf(filename, "testfile.%d", myrank);
10
       MPI_File_open(MPI_COMM_SELF, filename, MPI_MODE_WRONLY | MPI_MODE_CREATE,
11
   MPI_INFO_NULL, &myfile);
       MPI_File_write(myfile, buf, BUFSIZE, MPI_INT, MPI_STATUS_IGNORE);
12
       MPI_File_close(&myfile);
13
   <MPI Basis::deinit ?? >
```

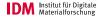
Quelle: [GLT99], http://www.mcs.anl.gov/research/projects/mpi/usingmpi2/examples/starting/main.htm, 01.12.2013



### Eine Datei für alle Prozesse







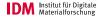
### MPI\_File\_write\_at

## Aufgabe

Schreiben an einer bestimmten Position in der Datei

```
int MPI_File_write_at(
  MPI_File mpi_fh,
                            //[in] file
                                      handle
  MPI_Offset offset,
                       //[in] file offset
  void *buf,
                                         address
  int count,
                            //[in] number of
                                          elements
  MPI_Datatype datatype, //[in] datatype of each
                                                  buffer
  MPI Status *status
                            //fout1 status
                                         object
```





### MPI\_File\_read\_at

# Aufgabe

Lesen ab einer bestimmten Postion in der Datei

```
int MPI_File_read_at(
  MPI_File mpi_fh,
                            //[in] file
                                       handle
  MPI_Offset offset,
                        //[in] file offset
  void *buf,
                            //foutl initial
                                            address
  int count,
                             //[in] number of
                                             elements
  MPI_Datatype datatype, //[in] datatype of each
                                                    buffer
  MPI Status *status
                            //foutl status
                                          object
```



### MPI-IO: eine Datei für alle Prozesse

```
example of parallel MPI write into a single file */
   <MPI Basis::init ?? >
   #define BUFSIZE 100
       int i, myrank, buf[BUFSIZE];
       MPI File thefile:
       MPI_Init(&argc, &argv);
       MPI_Comm_rank(MPI_COMM_WORLD, &mvrank);
       for (i=0; i<BUFSIZE; i++)</pre>
           buf[i] = myrank * BUFSIZE + i;
10
       MPI_File_open(MPI_COMM_WORLD. "testfile".
11
         MPI_MODE_CREATE | MPI_MODE_WRONLY,
12
         MPI_INFO_NULL, &thefile):
13
       MPI_File_write_at(thefile, myrank * BUFSIZE * sizeof(int), buf,
         BUFSIZE, MPI_INT, MPI_STATUS_IGNORE);
15
       MPI_File_close(&thefile);
16
   <MPI Basis::deinit ?? >
```

Quelle: [GLT99], http://www.mcs.anl.gov/research/projects/mpi/usingmpi2/examples/starting/main.htm, 01.12.2013





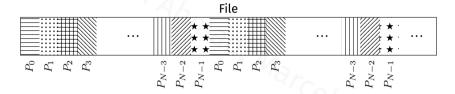
### MPI\_File\_set\_view

## Aufgabe

Setzen eines "Fensters" auf die Datei



#### Eine Datei für alle Prozesse





#### MPI-IO: eine Datei für alle Prozesse

```
of parallel MPI write into a single
   <MPI Basis::init ?? >
   #define BUFSIZE 100
       int i, myrank, buf[BUFSIZE];
       MPI_File thefile;
       MPI_Init(&argc, &argv);
       MPI_Comm_rank(MPI_COMM_WORLD, &mvrank);
       for (i=0: i<BUFSIZE: i++)</pre>
           buf[i] = mvrank * BUFSIZE + i;
10
       MPI_File_open(MPI_COMM_WORLD, "testfile",
11
         MPI_MODE_CREATE | MPI_MODE_WRONLY.
12
         MPI_INFO_NULL, &thefile):
13
       MPI_File_set_view(thefile, myrank * BUFSIZE * sizeof(int).
14
         MPI_INT, MPI_INT, "native", MPI_INFO_NULL);
15
       MPI_File_write(thefile, buf, BUFSIZE, MPI_INT, MPI_STATUS_IGNORE):
16
       MPI File close(&thefile):
17
   <MPI Basis::deinit ?? >
```

Quelle: [GLT99], http://www.mcs.anl.gov/research/projects/mpi/usingmpi2/examples/starting/main.htm, 01.12.2013





Kleiner Exkurs: selbstdefinierte MPI-Typen





### MPI\_Type\_create\_subarray

### Aufgabe

Erzeugt einen neuen Datentyp der ein Untergitter in einem N-Dimensionalen regulären Raum beschreibt

```
int MPI_Type_create_subarray(
  int ndims.
                               //[in] number of
  int arrav_of_sizes[].
                            //[in] number of
                                               elements
                                                        of type
                                                                 oldtype
array
  int arrav_of_subsizes[]. //[in] number of elements
 subarray
  int array_of_starts[], //[in] starting
                                               coordinates
                                                                  subarray
                                                                           in each
  int order.
                                          storage
                                                   order
  MPI_Datatype oldtype, //[in] array
                                           element
                                                    datatune
  MPI_Datatype *newtype
                            //[out] new
                                          datatupe
```

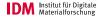


### MPI\_Type\_create\_subarray

### Order

MPI\_ORDER\_C row-major order wie bei C arrays
MPI\_ORDER\_FORTRAN column-major order wie bei Fortran arrays





### MPI\_Type\_commit

# Aufgabe

Neuen MPI-Typen bekannt machen zur späteren Verwendung

```
int MPI_Type_commit(
    MPI_Datatype *datatype //[in] datatype
);
```



### Weitere MPI Funktionen zur Erzeugung komplexe MPI Datentypen

MPI\_Type\_create\_hvector
MPI\_Type\_create\_resized
MPI\_Type\_create\_indexed\_block
MPI\_Type\_create\_hindexed
MPI\_Type\_create\_darray
MPI\_Type\_contiguous
MPI\_Type\_create\_struct





#### MPI-IO: Schreiben eines 2D zerlegten Gebiets I

```
<MPT Rasis .. init ?? >
                 gsizes[2], distribs[2], dargs[2], psizes[2], rank, size, m, n;
   int
   MPI_Datatype filetype;
                 local_array_size, num_local_rows, num_local_cols;
   int
                 row_procs, col_procs, row_rank, col_rank;
   int
                 dims[2], periods[2], lsizes[2], coords[2], start_indices[2];
   int
   MPI Comm
                 comm:
  MPI File
                 fh:
   float
                 *local_array:
  MPI_Status
                 status:
11
   /* This code is particular
                             to a 2 x 3 process
                                                 decomposition
12
  MPI_Comm_size( MPI_COMM_WORLD, &size );
   if (size != 6) {
14
     printf("Communicator size must be 6\n");
15
     MPI Abort ( MPI COMM WORLD, 1 ):
16
17
18
19
   /* number of points in each
                             direction
   m = 11: n = 15:
```



#### MPI-IO: Schreiben eines 2D zerlegten Gebiets II

```
/* See comments on block
22
                             distribution
   row_procs = 2;
23
   col_procs = 3;
   num_local_rows = (m + row_procs - 1) / row_procs;
   /* adjust for last row */
26
if (row_rank == row_procs-1)
     num_local_rows = m - (row_procs-1) * num_local_rows;
28
   num_local_cols = (n + col_procs - 1) / col_procs;
   /* adjust for last column */
30
   if (col_rank == col_procs-1)
31
     num_local_cols = n - (col_procs-1) * num_local_cols;
32
33
   local_array = (float *)malloc(num_local_rows * num_local_cols * sizeof(float));
34
35
36
   /* ... set elements of local_array
37
   gsizes[0] = m: /* no. of rows in alobal
   gsizes[1] = n; /* no. of columns in global array */
40
  lsizes[0] = num_local_rows; /* no. of rows in local
   lsizes[1] = num local cols: /* no. of columns in local array */
```



#### MPI-IO: Schreiben eines 2D zerlegten Gebiets III

```
dims[0] = 2;
  dims[1] = 3;
  periods[0] = periods[1] = 1;
  MPI Cart create (MPI COMM WORLD, 2, dims, periods, 0, &comm);
  MPI_Comm_rank(comm, &rank);
48
  MPI Cart coords(comm. rank. 2. coords):
49
50
51
   /* global indices of the first element of the local
   start indices[0] = coords[0] * lsizes[0]:
   start indices[1] = coords[1] * lsizes[1]:
54
  MPI_Type_create_subarray(2, gsizes, lsizes, start_indices,
55
     MPI_ORDER_C, MPI_FLOAT, &filetype):
56
  MPI_Type_commit(&filetype);
58
  MPI_File_open(MPI_COMM_WORLD, "/pfs/datafile".
     MPI MODE CREATE | MPI MODE WRONLY.
60
     MPI_INFO_NULL, &fh):
  MPI_File_set_view(fh, 0, MPI_FLOAT, filetype, "native",
     MPI INFO NULL):
   local_array_size = lsizes[0] * lsizes[1]:
```



#### MPI-IO: Schreiben eines 2D zerlegten Gebiets IV

```
MPI_File_write_all(fh, local_array, local_array_size,
MPI_FLOAT, &status);

MPI_File_close(&fh);

MPI_File_close(&fh);

MPI_File_close(&fh);
```

Quelle: [GLT99], http://www.mcs.anl.gov/research/projects/mpi/usingmpi2/examples/starting/main.htm, 01.12.2013





#### MPI-IO: Schreiben eines 2D zerlegten Gebiets mit Ghost-Layer I

```
<MPT Rasis .. init ?? >
                 gsizes[2], distribs[2], dargs[2], psizes[2], rank, size, m, n;
   int
                 lsizes[2], dims[2], periods[2], coords[2], start_indices[2];
   int
                 memsizes[2]:
   int
   MPI_Datatype filetype, memtype;
   MPI Comm
                 comm:
                 local_array_size, num_local_rows, num_local_cols;
   int
   int
                 row_procs, col_procs, row_rank, col_rank;
   MPI File
                 fh;
  float
                 *local_array:
   MPI Status
                 status:
12
   /* This code is particular to a 2 x 3 process
                                                 decomposition
13
   MPI_Comm_size(MPI_COMM_WORLD, &size);
   if (size != 6) {
     printf("Communicator size must be 6\n");
16
     MPI_Abort(MPI_COMM_WORLD, 1);
17
18
19
   /* number of points in each direction */
  m = 11: n = 15:
```



#### MPI-IO: Schreiben eines 2D zerlegten Gebiets mit Ghost-Layer II

```
22
23
   /* See comments on block
                             distribution
   row_procs = 2;
   col procs = 3:
   num_local_rows = (m + row_procs - 1) / row_procs;
   /* adjust for last row */
27
   if (row_rank == row_procs-1)
     num_local_rows = m - (row_procs-1) * num_local_rows;
29
   num_local_cols = (n + col_procs - 1) / col_procs;
   /* adjust for last column */
31
  if (col_rank == col_procs-1)
     num_local_cols = n - (col_procs-1) * num_local_cols;
33
34
   /* no. of rows and columns in alobal
   gsizes[0] = m;
                      gsizes[1] = n;
   /* no . of processes
                      in vertical
                                 and
                                      horizontal
                                                  dimensions
38
      of process grid */
lsizes[0] = num local rows: /* no. of rows in local
  lsizes[1] = num_local_cols; /* no. of columns in local array */
\dim [0] = 2; \dim [1] = 3;
   periods[0] = periods[1] = 1:
  MPI_Cart_create(MPI_COMM_WORLD, 2, dims, periods, 0, &comm);
```





### MPI-IO: Schreiben eines 2D zerlegten Gebiets mit Ghost-Layer III

```
MPI_Comm_rank(comm, &rank);
   MPI_Cart_coords(comm, rank, 2, coords);
   /* alobal indices of the first element of the local array */
   start indices[0] = coords[0] * lsizes[0]:
   start_indices[1] = coords[1] * lsizes[1];
49 MPI_Type_create_subarray(2, gsizes, lsizes, start_indices,
      MPI_ORDER_C, MPI_FLOAT, &filetype);
50
  MPI_Type_commit(&filetype);
51
  MPI_File_open(MPI_COMM_WORLD, "/pfs/datafile",
     MPI MODE CREATE | MPI MODE WRONLY.
53
     MPI_INFO_NULL, &fh);
  MPI_File_set_view(fh, 0, MPI_FLOAT, filetype, "native",
      MPI_INFO_NULL);
56
57
   /* add 4
             ghostlayers to each side and create a derived
                                                        datatupe
    * the layout of the local
                               array in the memory buffer
                                                        that includes
                                                                     the abost area */
   memsizes[0] = lsizes[0] + 8; /* no. of rows in allocated
   memsizes[1] = lsizes[1] + 8; /* no. of columns in allocated
   /* ... set elements of local array ... */
   local array = (float *)malloc(memsizes[0] * memsizes[1] * sizeof(float));
```



#### MPI-IO: Schreiben eines 2D zerlegten Gebiets mit Ghost-Layer IV

Quelle: [GLT99], http://www.mcs.anl.gov/research/projects/mpi/usingmpi2/examples/starting/main.htm, 01.12.2013

### **Kollektives MPI-IO**

- Kann viele kleine Chunks zu größeren zusammenfassen
- Weniger seeks bei z.B. kartesischen Topologien
- Höherer Lese-/Schreib-Durchsatz
- Alle Prozesse müssen Lese-/Schreib-Operation aufrufen (sonst Deadlock)





### MPI\_File\_write\_all

# Aufgabe

Kollektives Schreiben in eine Datei

```
int MPI_File_write_all(
MPI_File mpi_fh, //[in] file handle
void *buf, //[in] initial address of buffer
int count, //[in] number of elements in buffer
MPI_Datatype datatype, //[in] datatype of each buffer element
MPI_Status *status //[out] status object

7);
```





### MPI\_File\_read\_all

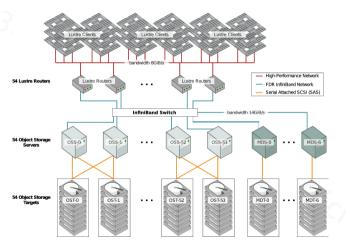
# Aufgabe

Kollektives Lesen aus einer Datei





#### Aufbau parallele Dateisystem



Quelle: https://link.springer.com/article/10.1007/s11227-021-03730-7, besucht 30.11.2021

### Hints for faster IO

- Optimieren des Lese-/Schreib-Prozesses durch zusätzliche Informationen
- dateisystemspezifische Parameter (z.B. NFS, XFS)
- Hardware/Software Struktur (z.B. Raid XX, OTS Anzahl)





#### MPI\_Info\_create

# Aufgabe

Erzeugt ein neues Info Objekt

```
int MPI_Info_create(
    MPI_Info *info //[out] info object created
);
```





### MPI\_Info\_set

## Aufgabe

Setzen eines Hints (Key/Value Paar)

```
int MPI_Info_set(
    MPI_Info info, //[in] info object
    char *key, //[in] key
    char *value //[in] value
);
```





#### MPI\_Info\_create

## Aufgabe

Löscht ein Info Objekt

```
int MPI_Info_free(
    MPI_Info *info //[in] info object to be freed
    );
```



#### MPI-IO: Hints für paralleles IO I

```
<MPT Basis .. init ?? >
        MPI File fh:
2
        MPI_Info info:
        MPI Info create(&info):
                     HINTS ARE
        /* no . of I/O devices across
                                     which the file should be striped */
        MPI_Info_set(info, "striping_factor", "4");
        /* the striping unit in bytes */
10
        MPI_Info_set(info, "striping_unit", "65536");
11
        /* buffer size for collective I/O */
12
        MPI_Info_set(info, "cb_buffer_size", "8388608");
13
        /* no . of processes
                            that should perform disk accesses
14
           during collective I/O */
15
        MPI_Info_set(info, "cb_nodes", "4");
16
17
18
            FOLLOWING
                   ARE
                        ADDITIONAL.
                                    HINTS
                                           SUPPORTED
19
        /* the I/O- device from which to start striping the file */
        MPI Info set(info, "start iodevice", "2"):
20
        /* buffer size for data sieving in independent reads */
```



#### MPI-IO: Hints für paralleles IO II

```
MPI Info set(info, "ind rd buffer size", "2097152"):
22
        /* buffer size for data sieving in independent writes */
23
        MPI_Info_set(info, "ind_wr_buffer_size", "1048576");
24
        /* use direct I/O on SGI's XFS file system
25
          ( platform - specific hints ) */
26
        MPI_Info_set(info, "direct_read", "true");
27
       MPI_Info_set(info, "direct_write", "true");
28
29
        /* NOW OPEN THE FILE WITH THIS INFO
30
                                            ORIECT
       MPI_File_open(MPI_COMM_WORLD, "/pfs/datafile",
31
          MPI_MODE_CREATE | MPI_MODE_RDWR, info, &fh);
32
33
       MPI_Info_free(&info): /* free the info object */
34
35
        /* ... access file ... */
36
37
       MPI File close( &fh ):
38
39
        /* ... */
40
   <MPI Basis::deinit ?? >
```

Quelle: [GLT99], http://www.mcs.anl.gov/research/projects/mpi/usingmpi2/examples/starting/main.htm, 01.12.2013

### **Grenzen von MPI**

- Redundanz (muss selbst implementiert werden)
- Fehlertoleranz
- $\blacksquare$  Skalierbarkeit bei > 1.000.000 CPUs (Managementaufwand)
- Debugging

### Zusammenfassung

- Gruppen und Communicatoren
- Virtuelle Topologien
- MPI-IO
- Komplexe MPI Datentypen

Fragen zur Vorlesung?

GEORGE ALMÁSI, RALPH BELLOFATTO, JOSÉ BRUNHEROTO, CĂLIN CAŞCAVAL, JOSÉ G. CASTAÑOS, PAUL CRUMLEY, C. CHRISTOPHER ERWAY, DEREK LIEBER, XAVIER MARTORELL, JOSÉ E. MOREIRA, RAMENDRA SAHOO, ALDA SANOMIYA, LUIS CEZE, and KARIN STRAUSS. An overview of the bluegene/l system software organization.

Parallel Processing Letters, 13(04):561–574, 2003.

Gene M. Amdahl.

Validity of the single processor approach to achieving large scale computing capabilities. In *Proceedings of the April 18-20, 1967, Spring Joint Computer Conference*, AFIPS '67 (Spring), pages 483–485, New York, NY, USA, 1967. ACM.

Clay Breshears.

The Art of Concurrency: A Thread Monkey's Guide to Writing Parallel Applications. O'Reilly Media, O edition, 5 2009.

David Culler, J.P. Singh, and Anoop Gupta.

Parallel Computer Architecture: A Hardware/Software Approach (The Morgan Kaufmann Series in Computer Architecture and Design).

Morgan Kaufmann, 1 edition, 8 1998.

- David Griffiths Dawn Griffiths.

  C von Kopf bis Fuß.

  O'Reilly Vlg. GmbH und Co., 9 2012.
- William James Dally and Brian Patrick Towles.

  Principles and Practices of Interconnection Networks (The Morgan Kaufmann Series in Computer Architecture and Design).

Morgan Kaufmann, 1 edition, 1 2004.

- Victor Eijkhout.

  Introduction to High Performance Scientific Computing.
  lulu.com, 10 2012.
- Message Passing Interface Forum.
  MPI: A Message-Passing Interface Standard, Version 3.0.
  High Performance Computing Center Stuttgart, 2012.
- Ananth Grama, George Karypis, Vipin Kumar, and Anshul Gupta.
  Introduction to Parallel Computing (2nd Edition).





Addison-Wesley, 2 edition, 1 2003.

William Gropp, Ewing L. Lusk, and Anthony Skjellum.

Using MPI - 2nd Edition: Portable Parallel Programming with the Message Passing Interface (Scientific and Engineering Computation).

The MIT Press, second edition edition, 11 1999.

William Gropp, Ewing L. Lusk, and Rajeev Thakur.
Using MPI-2: Advanced Features of the Message Passing Interface (Scientific and Engineering Computation).

The MIT Press, 1st edition, 11 1999.

John L. Gustafson.

Reevaluating amdahl's law.

Commun. ACM, 31(5):532–533, May 1988.

Georg Hager.

Introduction to high performance computing for scientists and engineers (chapman & hall/crc computational science), 9 2012.





David R. Hanson.

C Interfaces and Implementations: Techniques for Creating Reusable Software.

Addison-Wesley Professional, 1 edition, 8 1996.



J. Kim, W.J. Dally, S. Scott, and D. Abts.

Technology-driven, highly-scalable dragonfly topology.

In Computer Architecture, 2008. ISCA '08. 35th International Symposium on, pages 77–88, June 2008.



David Padua, editor.

Encyclopedia of Parallel Computing (Springer Reference).

Springer, 2011 edition, 9 2011.



Manish Parashar, Xiaolin Li, and Sumir Chandra.

Advanced Computational Infrastructures for Parallel and Distributed Applications (Wiley Series on Parallel and Distributed Computing).

Wiley-Interscience, 1 edition, 12 2009.



Thomas Rauber.

Parallele Programmierung (eXamen.press) (German Edition).

Springer, 3. aufl. 2012 edition, 9 2012.

Thomas Rauber and Gudula Rünger.
Parallele programmierung (examen.press) (german edition), 9 2012.

Josef Schüle.

Paralleles Rechnen.

Oldenbourg Wissensch.Vlg, 9 2010.

Anthony Skjellum.

MPI - Eine Einführung.

Oldenbourg Wissensch.Vlg, 6 2007.

Peter van der Linden.

Expert C Programming: Deep C Secrets.

Prentice Hall, 1st edition, 6 1994.

Eric F. Van de Velde.
Concurrent scientific computing.



Texts in applied mathematics; 16. Springer, New York, 1994.



G. Zumbusch.

Tuning a finite difference computation for parallel vector processors.

In Parallel and Distributed Computing (ISPDC), 2012 11th International Symposium on, pages 63–70, June 2012.